محمدمهدی لطفی نژاد
مشاوره، آموزش و پیاده‌سازی راهکارهای مبتنی بر داده و هوش مصنوعی

سرفصل دوره‌ی آموزشی

ارزیابی و پایش مدل‌های زبانی

LLM Evaluation & Observability

طراحی روند ارزیابی و پایش کاربردهای مبتنی بر مدل‌های زبانی؛ شامل مجموعه‌داده و معیارهای ارزیابی، داوری با مدل زبانی، ارزیابی RAG و ایجنت‌ها، ردگیری و پایش عملیاتی.

سطح دوره	مدت پیشنهادی	بخش و درس	شیوه‌ی برگزاری
متوسط	**۳ روز (۲۴ ساعت)**	**۹ بخش، ۴۱ درس**	**حضوری یا آنلاین**

آنچه شرکت‌کنندگان می‌آموزند

- توضیح اینکه چرا «ظاهراً درست کار می‌کند» دلیلی بر کارکرد درست یک قابلیت هوش مصنوعی نیست
- ساخت مجموعه‌داده‌ی مرجع که بازتاب استفاده‌ی واقعی باشد
- انتخاب میان معیارهای قطعی، مبتنی بر پاسخ مرجع و داوری با مدل زبانی
- ارزیابی تخصصی جریان‌های RAG و ایجنت‌های ابزارمحور
- ردگیری، پایش و محافظت از اپلیکیشن مبتنی بر مدل زبانی در محیط عملیاتی

پیش‌نیازها

- تسلط بر پایتون
- تجربه‌ی ساخت یا کار روی یک اپلیکیشن مبتنی بر مدل زبانی؛ این دوره ارزیابی آن را آموزش می‌دهد، نه ساخت اولین اپلیکیشن
- دسترسی به API یک مدل زبانی برای تمرین‌های عملی

ابزارها و فناوری‌ها

Pydantic · Anthropic SDK (Claude) · scikit-learn · ROUGE & NLTK

پروژه‌ی عملی

سامانه‌ی ارزیابی و پایش برای یک اپلیکیشن مبتنی بر مدل زبانی

سرفصل‌های دوره

۱ چرا ارزیابی اهمیت دارد — ۵ درس

۱. دام «ظاهراً درست است»
۲. ارزیابی آفلاین در برابر آنلاین
۳. نگرش ارزیابی‌محور
۴. چه چیزی را بسنجیم: ابعاد کیفیت
۵. **پروژه‌ی راهنمادار: اولین سامانه‌ی ارزیابی**

۲ ساخت مجموعه‌داده‌ی ارزیابی — ۵ درس

۱. مجموعه‌ی مرجع: ویژگی‌های یک مجموعه‌داده‌ی ارزیابی خوب
۲. نوشتن دستی موارد آزمون
۳. از گزارش‌های عملیاتی تا مجموعه‌ی آزمون
۴. پوشش، تفکیک و پاکیزگی مجموعه‌داده
۵. **پروژه‌ی راهنمادار: ساخت مجموعه‌ی مرجع برای Docent**

۳ معیارهای قطعی و مبتنی بر پاسخ مرجع — ۵ درس

۱. تطابق دقیق و یکسان‌سازی
۲. F1 در سطح توکن و معیارهای هم‌پوشانی
۳. معیارهای ROUGE، BLEU و N-gram
۴. بررسی خروجی ساختاریافته و Schema
۵. **پروژه‌ی راهنمادار: کارنامه‌ی معیارهای مرجع**

۴ داوری با مدل زبانی (LLM-as-Judge) — ۵ درس

۱. چرا و چه زمانی از مدل زبانی به‌عنوان داور استفاده کنیم
۲. امتیازدهی مستقیم با سنجه‌نامه
۳. مقایسه‌ی دوبه‌دو و ترجیح
۴. واسنجی داور و اعتماد به آن
۵. **پروژه‌ی راهنمادار: داور واسنجی‌شده برای Docent**

۵ ارزیابی RAG — ۵ درس

۱. مسئله‌ی ارزیابی RAG: دو سامانه در یک سامانه
۲. معیارهای بازیابی: Precision، Recall، MRR و NDCG
۳. وفاداری به منبع و مستندبودن پاسخ
۴. مرتبط‌بودن پاسخ و کیفیت زمینه
۵. **پروژه‌ی راهنمادار: ارزیابی کامل یک RAG**

۶ ارزیابی ایجنت‌ها و به‌کارگیری ابزار — ۵ درس

۱. چرا ارزیابی ایجنت‌ها دشوارتر است
۲. معیارهای موفقیت در انجام وظیفه و نتیجه
۳. درستی فراخوانی ابزار
۴. ارزیابی مسیر حرکت ایجنت
۵. **پروژه‌ی راهنمادار: ارزیابی نسخه‌ی ایجنتیک Docent**

۷ پایش‌پذیری و ردگیری

۵ درس

۱. از ارزیابی تا پایش‌پذیری
۲. ثبت ساختاریافته‌ی فراخوانی‌های مدل
۳. Trace و Span: دنبال‌کردن یک درخواست
۴. حسابرسی هزینه، تأخیر و توکن
۵. **پروژه‌ی راهنمادار: ابزارگذاری Docent برای پایش**

۸ پایش در محیط عملیاتی و سازوکارهای محافظتی

۵ درس

۱. پایش در محیط عملیاتی: داشبورد و هشدار
۲. تشخیص رانش و افت عملکرد
۳. آزمون پسرفت پرامپت و مدل در CI
۴. سازوکارهای محافظتی و بازخورد انسانی
۵. **پروژه‌ی راهنمادار: سامانه‌ی پایش و محافظت**

۹ پروژه‌ی پایانی

۱ درس

۱. **پروژه‌ی راهنمادار: سامانه‌ی کامل ارزیابی و پایش**

درخواست برگزاری اختصاصی این دوره برای سازمان شما

سرفصل، مدت، سطح و تمرین‌های دوره بر اساس نیاز تیم شما تنظیم می‌شود و آموزش به زبان فارسی، به‌صورت حضوری یا آنلاین برگزار می‌شود. برای ثبت درخواست، فرم مربوط به همین دوره را تکمیل کنید.

ثبت درخواست این دوره

lotfinejad.ir/contact