محمدمهدی لطفی نژاد
مشاوره، آموزش و پیاده‌سازی راهکارهای مبتنی بر داده و هوش مصنوعی

مهندسی داده

سرفصل دوره‌ی آموزشی

پردازش کلان‌داده با PySpark

PySpark for Data Engineering

آموزش عملی Apache Spark در محیط محلی؛ شامل معماری اجرا، DataFrame و Spark SQL، بهینه‌سازی پارتیشن و Shuffle، و ساخت جریان ETL همراه با کنترل کیفیت و ثبت رویداد.

سطح دوره	مدت پیشنهادی	بخش و درس	شیوه‌ی برگزاری
متوسط	**۲ روز (۱۶ ساعت)**	**۸ بخش، ۳۶ درس**	**حضوری یا آنلاین**

آنچه شرکت‌کنندگان می‌آموزند

- توضیح نقش واقعی Driver، Executor و طرح اجرای Lazy
- کار با DataFrame و Spark SQL روی ده میلیون رکورد واقعی
- خواندن طرح اجرا و کنترل پارتیشن‌ها، Shuffle و کش
- ساخت جریان ETL در قالب محیط عملیاتی با کنترل کیفیت و ثبت رویداد

پیش‌نیازها

- تسلط بر پایتون و pandas
- بهتر است پس از دوره‌ی «پایتون مقیاس‌پذیر برای مهندسی داده» گذرانده شود
- رایانه‌ای که بتواند Spark را به‌صورت محلی اجرا کند؛ نیازی به خوشه یا حساب ابری نیست

ابزارها و فناوری‌ها

PySpark (حالت محلی) · pandas · PyArrow

پروژه‌ی عملی

جریان کامل ETL با Spark روی داده‌های واقعی تاکسی نیویورک

سرفصل‌های دوره

۱ چرا پردازش توزیع‌شده؟ — ۵ درس

۱. سقف توان یک رایانه
۲. Driver، Executor و حالت محلی
۳. اولین SparkSession
۴. Spark چه زمانی برتری دارد (و چه زمانی نه)
۵. **پروژه‌ی راهنمادار: داده‌ی یک فصل در Spark**

۲ SparkSession، RDD و ارزیابی Lazy — ۵ درس

۱. تبدیل‌ها در برابر اقدام‌ها
۲. RDD در لایه‌های زیرین
۳. گراف DAG: Job، Stage و Task
۴. تغییرناپذیری و تبارنامه‌ی داده
۵. **پروژه‌ی راهنمادار: ردگیری کامل یک Job**

۳ DataFrame و تبدیل‌ها — ۵ درس

۱. ستون‌ها و عبارت‌ها
۲. فیلتر و پاک‌سازی
۳. Join
۴. گروه‌بندی و تجمیع
۵. **پروژه‌ی راهنمادار: گزارش منطقه–ساعت در Spark**

۴ Spark SQL و طرح اجرا — ۵ درس

۱. View موقت و SQL
۲. خواندن خروجی explain().
۳. بهینه‌سازی‌های Catalyst
۴. توابع تعریف‌شده‌ی کاربر و هزینه‌ی آن‌ها
۵. **پروژه‌ی راهنمادار: بهینه‌سازی یک کوئری کند**

۵ پارتیشن، Shuffle و کش — ۵ درس

۱. پارتیشن‌ها
۲. تبدیل‌های باریک و پهن: Shuffle
۳. کش و ماندگاری
۴. عدم توازن داده و کارهای عقب‌مانده
۵. **پروژه‌ی راهنمادار: بهینه‌سازی Job منطقه–ساعت**

۶ ساخت جریان ETL در Spark — ۵ درس

۱. Schemaها
۲. خواندن ← پاک‌سازی ← تبدیل
۳. نوشتن نتایج
۴. Jobهای تکرارپذیر بدون اثر جانبی
۵. **پروژه‌ی راهنمادار: ETL فصلی**

۷ کیفیت داده و ثبت رویداد

۵ درس

۱. قواعد اعتبارسنجی
۲. الگوهای قرنطینه‌ی داده
۳. ثبت ساختاریافته‌ی رویدادها
۴. شکست آشکار و به‌موقع
۵. **پروژه‌ی راهنمادار: اجرای ETL همراه با کنترل کیفیت**

۸ پروژه‌ی پایانی

۱ درس

۱. **پروژه‌ی پایانی: جریان Spark عملیاتی شرکت CityFlow**

درخواست برگزاری اختصاصی این دوره برای سازمان شما

سرفصل، مدت، سطح و تمرین‌های دوره بر اساس نیاز تیم شما تنظیم می‌شود و آموزش به زبان فارسی، به‌صورت حضوری یا آنلاین برگزار می‌شود. برای ثبت درخواست، فرم مربوط به همین دوره را تکمیل کنید.

ثبت درخواست این دوره

lotfinejad.ir/contact