محمدمهدی لطفی نژاد
مشاوره، آموزش و پیاده‌سازی راهکارهای مبتنی بر داده و هوش مصنوعی

سرفصل دوره‌ی آموزشی

پایتون مقیاس‌پذیر برای مهندسی داده

Scaling Python for Data Engineering

آموزش پردازش داده‌های بزرگ‌تر از حافظه با پایتون؛ شامل مدیریت مصرف حافظه، بارگذاری هدفمند، پردازش تکه‌ای و موازی‌سازی، همراه با تمرین روی داده‌های واقعی تاکسی نیویورک.

سطح دوره	مدت پیشنهادی	بخش و درس	شیوه‌ی برگزاری
مقدماتی تا متوسط	**۲ روز (۱۶ ساعت)**	**۸ بخش، ۳۶ درس**	**حضوری یا آنلاین**

آنچه شرکت‌کنندگان می‌آموزند

- اندازه‌گیری هزینه‌ی واقعی داده در حافظه و کاهش آن با انتخاب نوع داده‌ی مناسب
- بارگذاری فقط داده‌ی موردنیاز و پردازش تکه‌تکه‌ی داده‌های بزرگ‌تر از حافظه
- استفاده از NumPy و pandas در مقیاسی که کد ساده دیگر جواب نمی‌دهد
- موازی‌سازی پردازش روی چند هسته‌ی پردازنده
- انتخاب ساختمان‌های داده‌ای که جریان‌های واقعی بر پایه‌ی آن‌ها ساخته می‌شوند

پیش‌نیازها

- تسلط بر پایتون
- آشنایی کاربردی با مبانی pandas: خواندن CSV، انتخاب ستون، گروه‌بندی و تجمیع

ابزارها و فناوری‌ها

Python 3 · pandas · NumPy · PyArrow

پروژه‌ی عملی

یک جریان پردازش برای داده‌های بزرگ‌تر از حافظه روی داده‌های تاکسی نیویورک

سرفصل‌های دوره

۱ وقتی داده از حافظه بزرگ‌تر می‌شود — ۵ درس

۱. دیوار حافظه
۲. سنجش مصرف حافظه و انواع داده
۳. جعبه‌ابزار مهندس داده
۴. بارگذاری فقط داده‌ی موردنیاز
۵. **پروژه‌ی راهنمادار: بررسی داده‌های تاکسی نیویورک**

۲ NumPy برای مهندسی داده

۵ درس

۱. چرا NumPy
۲. نوع داده، دقت و حافظه
۳. برداری‌سازی: از حلقه تا عملیات آرایه‌ای
۴. انتشار (Broadcasting)
۵. **پروژه‌ی راهنمادار: شاخص‌های سفر با NumPy**

۳ pandas در مقیاس بزرگ

۵ درس

۱. کاهش اندازه‌ی نوع داده‌های عددی
۲. داده‌های دسته‌ای (Categorical)
۳. عملیات کارآمد و پرهیز از کپی‌های اضافه
۴. گروه‌بندی و تجمیع سریع
۵. **پروژه‌ی راهنمادار: بارگذار کم‌مصرف داده‌های تاکسی**

۴ پردازش تکه‌تکه و فراتر از حافظه

۵ درس

۱. ایده‌ی تکه‌بندی داده
۲. تجمیع جریانی
۳. SQLite به‌عنوان انبار داده‌ی محلی
۴. جریان‌های پردازش افزایشی و قابل ازسرگیری
۵. **پروژه‌ی راهنمادار: تجمیع داده‌ی چندماهه‌ای که در حافظه جا نمی‌شود**

۵ پردازش موازی

۵ درس

۱. چرا موازی‌سازی (و قفل سراسری مفسر)
۲. multiprocessing و Process Pool
۳. الگوی MapReduce
۴. پردازش موازی تکه‌های داده
۵. **پروژه‌ی راهنمادار: تجمیع موازی همراه با اندازه‌گیری**

۶ ساختمان‌های داده برای کار با داده

۵ درس

۱. دیکشنری و مجموعه: جست‌وجوی O(1) و حذف تکراری‌ها
۲. پشته و صف
۳. هیپ و صف اولویت
۴. انتخاب ساختار مناسب
۵. **پروژه‌ی راهنمادار: ایندکس درون‌حافظه‌ای و Top-N**

۷ بازگشت و درخت

۵ درس

۱. بازگشت برای پردازش داده
۲. درخت جست‌وجوی دودویی
۳. درخت برای مرتب‌سازی و ادغام
۴. ایندکس‌گذاری یک فایل
۵. **پروژه‌ی راهنمادار: ایندکس بازه‌ی زمانی روی داده‌های تاکسی**

۸ پروژه‌ی پایانی

۱ درس

۰۱ **پروژه‌ی پایانی: جریان تحلیلی برای داده‌های بزرگ‌تر از حافظه**

درخواست برگزاری اختصاصی این دوره برای سازمان شما

سرفصل، مدت، سطح و تمرین‌های دوره بر اساس نیاز تیم شما تنظیم می‌شود و آموزش به زبان فارسی، به‌صورت حضوری یا آنلاین برگزار می‌شود. برای ثبت درخواست، فرم مربوط به همین دوره را تکمیل کنید.

ثبت درخواست این دوره

lotfinejad.ir/contact